

Series de Tiempo: Notas modelos ARIMA

Martín Prado

November 27, 2024

1 Repaso de Estimación de modelos ARMA

3.4 Función de Autocorelación Parcial (pacf)

Para una serie de tiempo estacionaria $(X_t)_{t \in \mathbb{Z}}$ de media 0, función de autocovarianza $\gamma(h) = \mathbf{E}[X_{t+h} X_t] = \mathbf{E}[X_h X_0]$ y función de autocorrelación $\rho(h) = \gamma(h)/\gamma(0)$, la función de autocorrelación parcial se define como

$$\alpha(1) = \text{corr}(X_2, X_1) = \rho(1)$$

$$\alpha(k) = \text{corr}(X_{k+1} - P_{\text{sp}\{1, X_2, \dots, X_k\}} X_{k+1}, X_{k+1} - P_{\text{sp}\{1, X_2, \dots, X_k\}} X_1)$$

Por otro lado, si definimos $\mathcal{H}_n := \overline{\text{sp}}\{X_1, \dots, X_n\}$ y $\hat{X}_{n+1} := P_{\mathcal{H}_n}(X_{n+1})$, del sistema de ecuaciones

$$R_k \alpha_k = \rho_k,$$

en donde $[R_k]_{ij} = \rho(i-j)$, $\rho_k = (\rho(1), \dots, \rho(k))'$, se sigue que el vector de soluciones $\alpha_k = (\alpha_{k1}, \dots, \alpha_{kk})'$ satisface $\alpha(k) = \alpha_k$.

7.2 Estimación de la función de autocorrelación

El estimador de la media es $\bar{X}_n = n^{-1} \sum_{k=1}^n X_k$ y el de la función de autocovarianza es

$$\hat{\gamma}(h) = \frac{1}{n} \sum_{t=1}^{n-h} (X_t - \bar{X}_n)(X_{t+h} - \bar{X}_n).$$

El estimador de la función de autocorrelación se define como

$$\hat{\rho}(h) = \hat{\gamma}(h)/\hat{\gamma}(0),$$

y el de la matriz de covarianza es

$$\hat{\Gamma}_n = \begin{bmatrix} \hat{\gamma}(0) & \hat{\gamma}(0) & \cdots & \hat{\gamma}(n-1) \\ \hat{\gamma}(1) & \hat{\gamma}(0) & \cdots & \hat{\gamma}(n-2) \\ \vdots & & & \\ \hat{\gamma}(n-1) & \hat{\gamma}(n-2) & \cdots & \hat{\gamma}(0) \end{bmatrix}$$

8.1 Ecuaciones Yule-Walker

Para un proceso $\mathbf{AR}(p)$ causal de media 0

$$X_t - \phi_1 X_{t-1} - \dots - \phi_p X_{t-p} = Z_t, \quad Z_t \sim \mathbf{WN}(0, \sigma^2),$$

y función de autocovarianza $\gamma(h) = \mathbf{E}[X_h X_0]$, tenemos que

$$\Gamma_p \Phi = \gamma_p,$$

en donde $[\Gamma_p]_{ij} = \gamma_{ij}(i - j)$, $\Phi = (\phi_1, \dots, \phi_p)'$ y $\gamma_p = (\gamma(1), \dots, \gamma(p))'$. En particular, si tomamos los estimados de la función de autocovarianza muestral $\hat{\gamma}$, podemos estimar los coeficientes del proceso $\mathbf{AR}(p)$ como la solución del vector $\hat{\Phi} = (\hat{\phi}_1, \dots, \hat{\phi}_p)'$ en la ecuación

$$\hat{\Gamma}_p \hat{\Phi} = \hat{\gamma}_p, \quad \hat{\gamma}_p = (\hat{\gamma}(1), \dots, \hat{\gamma}(p))'.$$

8.3 Estimados de coeficientes de Innovación

Para una muestra X_t del modelo $\mathbf{MA}(q)$

$$X_t = Z'_t + \theta_1 Z'_{t-1} + \dots + \theta_q Z'_{t-q}, \quad Z'_t \sim \mathbf{WN}(0, \sigma^2),$$

se puede realizar un ajuste de los coeficientes con el algoritmo de innovaciones para obtener

$$X_t = Z_t + \hat{\theta}_{m1} Z_{t-1} + \dots + \hat{\theta}_{mm} Z_{t-m}, \quad Z_t \sim \mathbf{WN}(0, \hat{v}_m)$$

con $\hat{\theta}_{ij}$ y \hat{v}_m definidos a partir de la relación recursiva

$$\hat{\theta}_{m,m-k} = \hat{v}_k^{-1} \left[\hat{\gamma}(m-k) - \sum_{j=0}^{k-1} \hat{\theta}_{m,m-j} \hat{\theta}_{k,k-j} \hat{v}_j \right], \quad k = 0, \dots, m-1,$$

y

$$\hat{v}_m = \hat{\gamma}(0) - \sum_{j=0}^{m-1} \hat{\theta}_{m,m-j}^2 \hat{v}_j.$$

8.4 Estimados de coeficientes de Innovación

En particular, para procesos $\mathbf{ARMA}(p, q)$ de media cero y causales

$$\phi(B)X_t = X_t - \phi_1 X_{t-1} - \dots - \phi_p X_{t-p} = Z_t + \theta_1 Z_{t-1} + \dots + \theta_q Z_{t-q} = \theta(B)Z_t,$$

podemos encontrar una función ψ que satisfice

$$X_t = \psi(B)Z_t = \sum_{j=0}^{\infty} \psi_j Z_{t-j}.$$

Los coeficientes ψ_j satisfacen

$$\psi_0 = 1, \quad \psi_j = \theta_j + \sum_{i=1}^{\min(j,p)} \phi_i \psi_{j-i},$$

y por ende, con la fórmula del capítulo 8.3 podemos estimar $\psi_1, \dots, \psi_{p+q}$ con $\hat{\theta}_{m1}, \dots, \hat{\theta}_{m,p+q}$, para luego obtener estimadores $\hat{\phi}$ y $\hat{\theta}$ con la fórmula

$$\hat{\theta}_{mj} = \hat{\theta}_j + \sum_{i=1}^{\min(j,p)} \hat{\phi}_i \hat{\theta}_{m,j-i},$$

y también el estimador de la varianza del proceso **WN** con

$$\hat{\sigma}^2 = \hat{v}_m.$$

8.7 Estimadores de Máxima Verosimilitud y Mínimos Cuadrados

Para una realización X_1, \dots, X_n del proceso **ARMA** (p, q) definido en la sección anterior (con Z_t Gaussianas), definimos $\boldsymbol{\phi} = (\phi_1, \dots, \phi_p)'$, $\boldsymbol{\theta} = (\theta_1, \dots, \theta_q)'$, los coeficientes θ_{ij} "reales" del algoritmo de Innovación:

$$\begin{cases} \hat{X}_{i+1} = \sum_{j=1}^i \theta_{ij} (X_{i+1-j} - \hat{X}_{i+1-j}), & 1 \leq i < m = \max(p, q) \\ \hat{X}_{i+1} = \phi(B)X_i + \sum_{j=1}^i \theta_{ij} (X_{i+1-j} - \hat{X}_{i+1-j}), & i \geq m \end{cases}$$

y además,

$$r_i := \mathbf{E} [(X_{i+1} - \hat{X}_{i+1})^2] / \sigma^2.$$

La función de verosimilitud de los parámetros del proceso **ARMA** es

$$L(\boldsymbol{\phi}, \boldsymbol{\theta}, \sigma^2) = (2\pi\sigma^2)^{-n/2} (r_0 \dots r_{n-1})^{-1/2} \exp \left[-\frac{1}{2} \sigma^{-2} \sum_{j=1}^n (X_j - \hat{X}_j)^2 / r_{j-1} \right].$$

Después de derivar con respecto a σ^2 , tenemos que el estimador de máxima verosimilitud de la varianza es

$$\tilde{\sigma}^2 = n^{-1} S(\tilde{\boldsymbol{\phi}}, \tilde{\boldsymbol{\theta}}),$$

en donde

$$S(\tilde{\boldsymbol{\phi}}, \tilde{\boldsymbol{\theta}}) = \sum_{j=1}^n (X_j - \hat{X}_j)^2 / r_{j-1}$$

y $\tilde{\boldsymbol{\phi}}, \tilde{\boldsymbol{\theta}}$ son los valores de los parámetros $\boldsymbol{\phi}, \boldsymbol{\theta}$ que minimizan la función

$$l(\boldsymbol{\phi}, \boldsymbol{\theta}) = \ln(n^{-1} S(\boldsymbol{\phi}, \boldsymbol{\theta})) + n^{-1} \sum_{j=1}^n \ln r_{j-1}.$$

8.9

^

8.11

2 Modelos ARIMA y SARIMA

Técnicas de Identificación